

Reporte Ejecutivo

1. Resumen Ejecutivo

Este proyecto aplica un pipeline completo de Machine Learning sobre datos del sistema de salud colombiano y del servicio de atención ciudadana del Ministerio del Deporte. En el Bloque 1 se realizó un análisis exploratorio con PySpark sobre 200.000 registros del RIPS, identificando disparidades regionales significativas en la prestación de servicios médicos. El Bloque 2 aplicó aprendizaje no supervisado (PCA + K-Means) y clasificación supervisada (Regresión Logística y Random Forest), donde la Regresión Logística alcanzó un accuracy de 0.9981. El Bloque 3 analizó 1.996 PQRS reales del Ministerio del Deporte con TF-IDF y el modelo pre-entrenado RoBERTa de Hugging Face, logrando un F1 de 0.8287 en clasificación documental y revelando que el 95.6% del corpus presenta tono neutro según el análisis de sentimiento.

2. Metodología

Bloque 1 — Análisis Exploratorio con PySpark

Dataset utilizado:

Nombre: Registros Individuales de Prestación de Servicios de Salud – RIPS

Entidad: Ministerio de Salud y Protección Social – Colombia

Fuente: Datos Abiertos Colombia – datos.gov.co

URL de descarga: <https://www.datos.gov.co/resource/5e6c-5p2c.csv>

URL del dataset: <https://www.datos.gov.co/d/5e6c-5p2c>

Columnas: departamento, municipio, año, tipoatencion, diagnostico, numeroatenciones

Muestra utilizada: 200.000 registros

Se cargó el dataset con PySpark (200.000 filas, 6 columnas). Se aplicaron tres transformaciones: filtro de municipios con más de 100 atenciones, agrupación por departamento con suma de atenciones, y creación de columna nivel_atencion (ALTA/MEDIA/BAJA) con withColumn. La estadística descriptiva reveló asimetría positiva marcada (mediana = 3 atenciones, P75 = 10). Se detectó 0 duplicados y se identificaron valores atípicos mediante el método IQR. Se generaron dos visualizaciones: barras de atenciones por departamento y pie chart por tipo de atención.

Bloque 2 — Machine Learning con Spark ML

Dataset utilizado:

Nombre: Registros Individuales de Prestación de Servicios de Salud – RIPS

Entidad: Ministerio de Salud y Protección Social – Colombia

Fuente: Datos Abiertos Colombia – datos.gov.co

URL de descarga: <https://www.datos.gov.co/resource/5e6c-5p2c.csv>

URL del dataset: <https://www.datos.gov.co/d/5e6c-5p2c>

Columnas: departamento, municipio, año, tipoatencion, diagnostico, numeroatenciones

Muestra utilizada: 200.000 registros

Se construyó un pipeline con StringIndexer, OneHotEncoder, VectorAssembler y StandardScaler. Se aplicó PCA con 20 componentes que explican el 74.67% de la varianza acumulada. K-Means con método del codo (k=2 a 10) fue evaluado con Silhouette Score, seleccionando k=3 para interpretación por dominio. Para clasificación se definió nivel_atencion como variable objetivo, dividiendo el dataset en 160.249 registros de entrenamiento y 39.751 de prueba (80/20, semilla=123). Se aplicaron Regresión Logística y Random Forest, y CrossValidator con numTrees y maxDepth como hiperparámetros (AUC óptimo: 0.9979).

Bloque 3 — NLP y Modelo Pre-entrenado

Dataset utilizado:

Nombre: PQRS – Ministerio del Deporte

Entidad: Ministerio del Deporte – Colombia

Fuente: Datos Abiertos Colombia – datos.gov.co

URL de descarga: <https://www.datos.gov.co/resource/bx26-pux4.csv>

URL del dataset: <https://www.datos.gov.co/d/bx26-pux4>

Columnas usadas: ASUNTO (texto), TIPO (categoría de solicitud)

Muestra utilizada: 1.996 documentos

Se cargó un corpus de 1.996 PQRS reales del Ministerio del Deporte agrupadas en 3 categorías: Comunicación Oficial (1.125 docs), Petición Ciudadana (736 docs) y Asunto Jurídico-Financiero (135 docs). Se aplicó tokenización con RegexTokenizer, filtrado de stop words en español, y vectorización con CountVectorizer + IDF (vocabulario: 2.303 términos). Se entrenó Regresión Logística multiclase con CrossValidator. En paralelo se aplicó pysentimiento/robertuito-sentiment-analysis al corpus completo y se compararon ambos enfoques.

3. Resultados

Bloque 1

Antioquia y Bogotá D.C. concentran la mayor cantidad de atenciones del dataset RIPS, evidenciando fuertes desigualdades regionales. El 75% de los registros presenta 10 atenciones o menos (P75 = 10), con mediana de 3, reflejando que la mayoría de los municipios tienen baja demanda mientras los grandes centros urbanos generan valores atípicos significativos.

Bloque 2

La Regresión Logística fue el modelo ganador con accuracy = 0.9981, F1 = 0.9981 y AUC = 0.9913, clasificando correctamente 37.422 casos BAJA y 2.253 ALTA. El Random Forest con CrossValidator obtuvo AUC óptimo de 0.9979 (numTrees=100, maxDepth=10). La importancia de variables mostró que la variable numérica escalada concentra el 87.1% del poder predictivo, seguida por departamento Bogotá D.C. (6.0%) y municipio Barranquilla (3.2%).

Bloque 3

El modelo TF-IDF + Regresión Logística clasificó los tipos de PQRS con accuracy = 0.9639 y F1 = 0.8287. Las palabras con mayor poder predictivo para Comunicación Oficial fueron 'respuesta', 'oficio' y 'radicado'. RoBERTuito detectó que el 95.6% del corpus tiene tono neutro (1.909 docs), el 3.2% negativo (63 docs) y el 1.2% positivo (24 docs), coherente con el carácter formal de las comunicaciones institucionales.

4. Reflexión

Los tres bloques construyen una visión progresiva del funcionamiento del Estado colombiano. El Bloque 1 describe la desigualdad estructural del sistema de salud: pocos departamentos concentran la mayoría de atenciones, con una mediana nacional de apenas 3 registros. El Bloque 2 demuestra que esta desigualdad es altamente predecible (accuracy 0.9981) usando variables geográficas y de tipo de atención, habilitando modelos de planificación de recursos. El Bloque 3 agrega la dimensión comunicacional: las PQRS del Ministerio del Deporte son predominantemente neutrales y documentales, lo que indica que los ciudadanos interactúan con el Estado principalmente para trámites formales. Juntos, los tres bloques conectan la eficiencia operativa del sistema con la experiencia comunicacional del ciudadano.

5. Limitaciones

- El dataset RIPS corresponde a una muestra de 200.000 registros del total nacional, lo que puede subestimar patrones en municipios pequeños o periodos de alta estacionalidad epidemiológica.
- El corpus de PQRS proviene exclusivamente del Ministerio del Deporte, un sector con comunicaciones predominantemente formales. Los resultados de sentimiento no son generalizables a entidades con mayor diversidad emocional como salud o tránsito.
- RoBERTuito fue pre-entrenado en tweets informales en español, lo que limita su precisión en textos jurídico-administrativos como las PQRS institucionales.

6. Recomendaciones

- Verificar el desbalance de clases antes del entrenamiento en el Bloque 2, ya que la alta proporción de registros BAJA puede inflar el accuracy sin capturar bien la clase ALTA.
- Hacer fine-tuning de RoBERTuito con PQRS de salud o tránsito para mejorar la discriminación entre sentimientos en textos formales colombianos.
- Cruzar los datos RIPS con PQRS de salud de datos.gov.co para conectar carga de atención médica con satisfacción ciudadana en un único problema de dominio.