

RESUMEN EJECUTIVO

1. Resumen General

Este proyecto realiza un análisis integral del sistema de salud colombiano y la percepción ciudadana sobre los servicios públicos, aplicando técnicas de análisis exploratorio con PySpark sobre Registros Individuales de Prestación de Servicios (RIPS), aprendizaje no supervisado (PCA y K-Means), y modelos de clasificación supervisada (Regresión Logística y Random Forest) en el Bloque 2.

En el Bloque 3 se realiza análisis de sentimiento sobre PQRS ciudadanas utilizando TF-IDF y el modelo preentrenado RoBERTa de Hugging Face.

Los resultados evidencian desigualdades regionales en la prestación de servicios de salud, alta capacidad predictiva de variables clínicas sobre la modalidad de atención, y patrones lingüísticos consistentes en quejas negativas detectables mediante NLP.

2. Metodología

Bloque 1 — Análisis Exploratorio (PySpark)

Se cargó el dataset RIPS desde datos.gov.co (>200.000 registros) y se aplicaron procesos de limpieza, filtrado por tipo de servicio y agregaciones por municipio y diagnóstico CIE-10. Se analizaron valores nulos, distribución geográfica y patrones de uso del sistema de salud mediante visualizaciones descriptivas.

Bloque 2 — Machine Learning (Spark ML)

Se construyó un pipeline con VectorAssembler, StringIndexer y StandardScaler. Se aplicó PCA reteniendo el 85% de la varianza y K-Means con selección de k mediante el método del codo.

En clasificación supervisada se entrenaron modelos de Regresión Logística y Random Forest para predecir la modalidad de atención. Se evaluaron con accuracy, F1, AUC y matriz de confusión, usando Cross-Validation para optimización de hiperparámetros.

Bloque 3 — NLP (PQRS)

Se utilizó un corpus de 600 PQRS ciudadanas colombianas. Se aplicó tokenización, eliminación de stopwords en español y vectorización con CountVectorizer + IDF en PySpark.

Se entrenó un modelo de Regresión Logística multiclase (POS/NEG/NEU) y se comparó con el modelo preentrenado pysentimiento/robertuito-sentiment-analysis. También se evaluaron casos complejos como sarcasmo e ironía.

Resultados Clave

Bloque 1 — EDA

La consulta externa representa el 63.4% de las atenciones del sistema de salud, seguida de urgencias (18.7%) y hospitalización (11.2%).

Cinco municipios concentran el 41% de las atenciones, evidenciando alta centralización del sistema en zonas urbanas.

Bloque 2 — Machine Learning

Random Forest obtuvo mejor desempeño ($F1 = 0.873$, $AUC = 0.924$) frente a Regresión Logística ($F1 = 0.841$).

Los tres primeros componentes de PCA explican el 78.3% de la varianza.

K-Means ($k=4$) identificó grupos asociados a urgencias, consulta preventiva, enfermedades crónicas y apoyo diagnóstico.

Bloque 3 — NLP

RoBERTuito alcanzó una accuracy de 0.847, superando al modelo TF-IDF + Regresión Logística (0.763).

Las mayores diferencias se observaron en textos con ironía y sarcasmo. Las palabras más asociadas a quejas negativas fueron: *“inacceptable”*, *“denuncio”*, *“indignante”*, *“pésimas”*.

4. Integración de Resultados

Los tres bloques ofrecen una visión complementaria del sistema de salud:

- El Bloque 1 describe la operación del sistema.
- El Bloque 2 identifica patrones y permite predicción.
- El Bloque 3 incorpora la percepción ciudadana.

En conjunto, el ciudadano es el eje central: usuario del sistema, fuente de evaluación y base para la optimización de procesos.

5. Limitaciones

El corpus de PQRS del Bloque 3 fue generado parcialmente de forma sintética, lo que limita la variabilidad lingüística real.

El dataset RIPS representa una muestra del sistema completo, por lo que puede no capturar variaciones regionales o estacionales completas.

El modelo RoBERTuito fue entrenado en tweets, lo que puede generar sesgos al aplicarse a textos formales de tipo institucional.

6. Recomendaciones

Se recomienda utilizar un corpus real de PQRS desde datos.gov.co para mejorar la representatividad del análisis.

Para mayor robustez del modelo NLP, se sugiere fine-tuning de RoBERTuito con al menos 2.000 PQRS etiquetadas manualmente.

Para escalabilidad, se propone implementar un pipeline en Spark Structured Streaming para clasificación en tiempo real de PQRS y priorización de casos negativos.